

專題報告-電梯異常檢測(再平層)之研究

陽明交通大學 管科系/資工系 侯均頌

專案概述

- 目標：偵測「再平層」事件（電梯到站第一次對齊後，因誤差過大而進行第二次對齊），以降低人工巡檢負擔。
- 資料：馬達電流（channel 0）+ 六軸振動（門上 XYZ：channels 1-3；車廂/馬達背面 XYZ：channels 4-6），原始取樣率 8192 Hz，訓練前下採樣至約 256 Hz；實驗使用 0604-0605 的正常資料與 0607 的異常資料；切片聚焦 Stage 3-5。
- 方法：各自以正常資料、異常資料訓練兩個 **1D-CNN Autoencoder**；每筆樣本輸入後得到兩個 reconstruction loss（視作 2D 特徵），再用 SVM / Logistic Regression / kNN 做最後分類。
- 通道發現：門上 XYZ（1-3）較有訊號意義；車廂/馬達背面 XYZ（4-6）資訊性弱。電流（0）+ 門上振動（1,2,3）是最佳組合；包含 4-6 的組合準確率常掉到 ~0.7 或以下。
- 融合策略：電流模型與振動模型的輸出做 **bitwise OR**，以小幅犧牲 precision 換取更高 recall（務實符合維運場景）。
- 評估：採 **10 次完整管線重複實驗**（每次重新隨機劃分 train/test），彙整平均表現。

問題定義與資料描述

業務問題（再平層）

- 再平層定義：電梯到達某一樓層後，控制系統會進行一次「平層」動作，將車廂位置與樓層對齊。但若第一次平層誤差過大，電梯會再進行一次第二次平層（即「再平層」）。

異常意義

- 再平層雖然不是立即性的安全事故，但它往往是潛在問題的前兆。
- 根據公司內部的實務經驗，再平層的出現與後續的多種異常狀況（例如馬達老化、煞車失效、控制系統校正異常、門機故障）呈高度正相關。
- 因此，偵測再平層 ≈ 預警更多嚴重異常。

目前困境

- 公司原本依賴人工檢查（維修人員聽聲音或查看記錄）來判斷是否出現再平層。
- 人工檢查效率低、成本高，且受人員經驗影響。


專題目標

- 開發一套基於感測訊號的自動化異常檢測方法，讓系統能在早期就發現再平層，進而預防或降低後續異常風險，並大幅減少人工巡檢成本。


感測配置與通道

- **Channel 0**：馬達電流（amp）。
- **Channels 1–3**：門上振動 XYZ
- **Channels 4–6**：車廂／馬達背面振動 XYZ

實驗發現：門上 XYZ 資訊性高，車廂/馬達背面 XYZ 資訊性低。



channel 234



channel 567

x, y軸代表正常autoencoder與異常autoencoder的reconstruction loss (後續會提及)，一個點代表一個test樣本 (一個樣本是一個時間序列)

數據期間與採樣

- 正常資料：0604–0605；異常資料：0607。原始 8192 Hz，訓練前下採樣至 ~ 256 Hz。
- 關注片段：Stage 3–5（對應行車階段中最能表徵再平層的訊段）。

資料切分與數量

- 投影片標示劃分為 **Train/Validate = 85%/15%**，並列出數量：
- 正常：train 1240、valid 50、test 50
- 異常：train 62、valid 50、test 50（註：異常樣本稀少，故另留固定數量的驗證與測試，以保持評估公平。）

方法設計（Architecture & Pipeline）

雙自編碼器（Dual-AE）設計

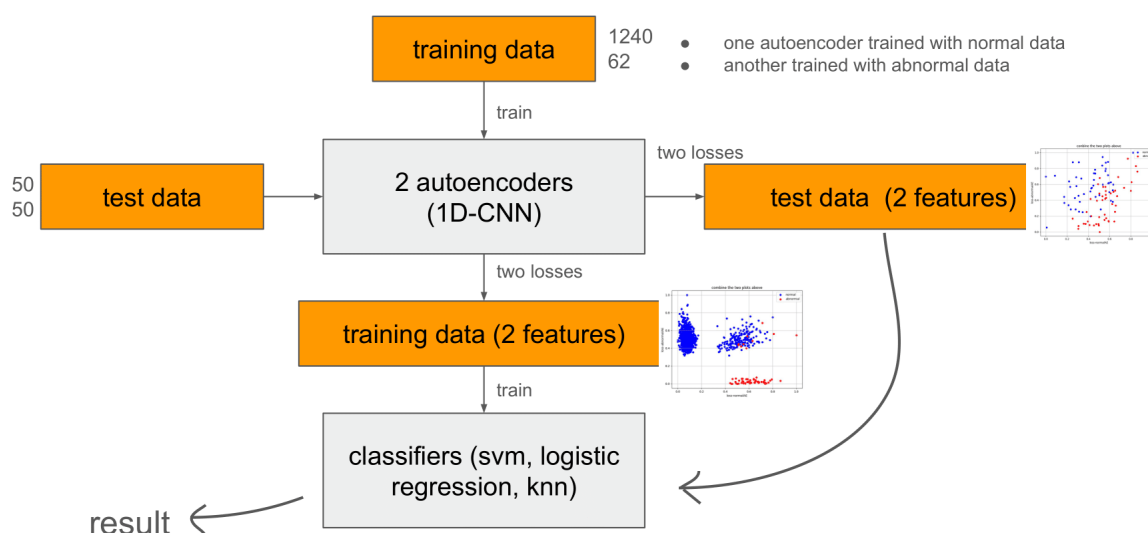
各自訓練兩個 1D-CNN Autoencoder：

1. **Normal-AE** (正常 autoencoder)：只用正常資料訓練
2. **Abnormal-AE** (異常 autoencoder)：只用異常資料訓練

推論時對每筆樣本分別計算 Normal-AE 與 Abnormal-AE 的 **reconstruction loss**；把兩個 loss 視作 **2D 特徵向**

量（ x =normal-loss, y =abnormal-loss），再餵入分類器（**SVM / Logistic Regression / kNN**）。

pipeline



通道與模型訓練策略

單通道建模

電流（Channel 0）

使用馬達電流單通道資料，訓練一對 Autoencoder。實驗結果：

- **Precision 較高（0.94）**，代表「判斷為異常時幾乎不會誤報」。
- 但 **Recall 偏低（0.62）**，異常檢出率不足。
- 適合作為 **高精確度但較保守** 的檢測器。

門上振動（Channels 1,2,3）

使用門上振動三軸資料，訓練另一對 Autoencoder。實驗結果：

- **Recall 較高（0.84）**，代表「異常檢出率較佳」。
- Precision 相對較低（0.82），誤報機率增加。
- 適合作為 **高靈敏度但較寬鬆** 的檢測器。

電流 + 門上振動（0,1,2,3）

- 嘗試將電流與振動直接合併輸入，但結果並沒有比單獨訓練更好。
- 原因推測為通道間訊號特性差異過大，導致 AE 難以同時兼顧。

後融合策略（OR）

由於單一模型各有優劣，採取 **OR** 融合：

- **OR 規則**：`pred_final = pred_amp OR pred_vib`
- 即若任一模型判斷為異常，則最終輸出異常。

優勢：

- Precision 稍微下降（0.82），但 Recall 大幅提升（0.92）。
- F1-Score 提升至 0.87，是三者最佳。
- 符合實務需求（寧可多報，不能漏報）。

實驗與結果

結果數據表

模型	Accuracy	Precision	Recall	F1-Score
Amp (電流0)	0.79	0.94	0.62	0.75
Vib (1,2,3)	0.83	0.82	0.84	0.83
Mix (OR)	0.86	0.82	0.92	0.87

- **結論**：電流（0）側重 Precision，門上振動（1,2,3）側重 Recall，兩者互補。透過 OR 融合，整體 F1 最佳，Recall 亦達到實務所需的水準。

單路結果（每路均為 Dual-AE → 2D loss → 分類器）


- 電流（0）：完成 train/test 評估（投影片給出混淆矩陣式標示 0/1）。
- 門上振動（1,2,3）：同上，完成 train/test 評估。

通道組合與表現

- 最佳：`[vibration 1,2,3] + [amp 0]`
- 次佳或不佳：`[0,1,2,3]`、`[2,3]`、`[0,2,3]` 等常 $\leq \sim 0.7$ accuracy（以相同的 train/test 集下測得）。
- 洞見：再次驗證 4-6 的資訊性偏弱；若強行加入，反而稀釋辨識訊息。

交叉驗證

- 完整管線重複 10 次，每次重新隨機劃分 Train/Test 後再做訓練與測試，最後彙整 平均結果 作為報告數字。



設計抉擇與理由

為何 AE 而非 VAE

- 目標是「重建誤差」本身；VAE 的機率建模與潛空間正則化在此非必要，AE 訓練更簡潔、較易穩定，且簡單測試之下 VAE 確實沒有優化分類結果。

為何 1D-CNN（不做 FFT）

- 再平層屬時域瞬時事件；1D-CNN 能直接學到局部時域形狀與跨通道關聯。頻域特徵未必優於學得的時域特徵，且 FFT 會引入額外窗口化選擇與相位處理成本，且簡單測試之下確實沒有優化分類結果。

雙 AE + 2D loss 的好處

- 相對「單一 AE + 閾值」，「Normal-AE vs Abnormal-AE」兩維 loss (如同二維平面) 讓邊界更清楚也更直觀（如：正常樣本在 Normal-AE 上 loss 低、在 Abnormal-AE 上 loss 高，反之亦然），線性或核化分類器即可取得乾淨決策邊界。

侷限與風險

- 異常樣本偏少（train 只有 62），泛化需小心；可以參考分層 **K-fold** 或時間分層的方式補強估計不確定性，或以重抽樣／類別權重平衡分類器。(此專案使用了 SMOTE 做法)
- 資料期間單一：僅使用 0604-0607；需在長週期、跨多台電梯上做時變漂移（**concept drift**）評估與更新策略。
- 尚未落地：流程未串上即時資料流與告警回饋迴路，須補上部屬與維運面。

可落地化的下一步（Roadmap）

評估指標調校：

- 明確追蹤 **Recall / Precision / F1 / AUROC** 與 告警頻率；以 ROC/PR-Curve 在不同閾值與分類器設定下找 sweet spot。

模型管理：

- 每台電梯一組模型 vs 全域模型 + 微調；加上 週／月回訓 與 資料漂移監測（如 PSI、KS）。

跨通道早期融合：

- 嘗試在 encoder 端做多通道卷積與注意力（仍保留後端 OR 作保險），觀察是否能在不吞噬 recall 的情況下提升 precision。
-

學生貢獻說明

專案參與階段

前期：主要輔佐碩班學長寫程式，協助開會時產出所需的數據展示工具。

中後期：因學長前往中國，聯繫變少後轉為獨自開發並進行實驗。

再平層相關交付：一直由學長負責，但到後期整個專案在再平層那塊逐漸放棄。

個人重點貢獻

實驗數據完整性

專注於完整的測試實驗數據，親自進行實驗並設計能提高準確率的演算法

算法創新：

- 早期單 autoencoder 階段的程式碼曾被學長使用，但後續開發完全獨立完成
- 雙 **autoencoder** 架構設計與實作
- **2D** 資料分類器（SVM、Logistic Regression 等）的開發
- **OR operation** 融合策略的發想與實作

實驗驗證

期末前完成的良好異常檢測分類結果，並使用 cross validation 進行驗證

報告撰寫

以上報告與實驗內容全部由本人完成

[專題 github 連結](#)

指導教授簽名確認：
